

Simulation en Biologie

Bruno Toupance

Univ Paris Diderot

SEP 2018

- Modèles déterministes : Analyses numériques
 - Récurrences
 - Équations différentielles
- Modèles stochastiques : Simulations
 - Génération de nombres aléatoires
 - Méthodes de Monte-Carlo



Casino de
Monte-Carlo

- Étude du comportement d'un système complexe
- Étude empirique des fluctuations d'échantillonnage
- Détermination des propriétés probabilistes d'une variable aléatoire de loi inconnue (bootstrap)
- Validation d'un modèle probabiliste
- Calcul d'intégrales, d'espérances, de vraisemblances



Georges-Louis
Leclerc, comte
de Buffon
(1707-1788)


- Détermination expérimentale de la valeur de π
- Dispositif expérimental :
 - Lames de parquet de largeur D
 - Aiguille de longueur L
 - On lance l'aiguille n fois
 - On compte le nombre de lancers n_S pour lesquels l'aiguille chevauche deux lames
 - Estimation de la probabilité que l'aiguille chevauche deux lames :

$$\hat{p} = \frac{n_S}{n}$$

- On peut par ailleurs montrer que :

$$p = \frac{2L}{\pi D} \quad \text{donc} \quad \pi \simeq 2 \frac{1}{\hat{p}} \frac{L}{D}$$


Aiguille de Buffon - Simulation 1



- Nombre de lancers : $n = 20$
- Rapport $\frac{L}{D} = 0.4$
- Proportion de succès :
 $p = \frac{6}{20} = 0.3$
- Estimation :

$$\hat{\pi} = 2.666667$$

Aiguille de Buffon - Simulation 2




- Nombre de lancers : $n = 500$
- Rapport $\frac{L}{D} = 0.4$
- Proportion de succès :
 $p = \frac{123}{500} = 0.246$
- Estimation :

$$\hat{\pi} = 3.252033$$

Aiguille de Buffon - Nombre de lancers


Qualité de l'estimateur en fonction du nombre de lancers

Aiguille de Buffon



- Rapport $\frac{L}{D} = 0.4$
- Nombre de lancers :
 $n = 1, 2, \dots, 10000$
- 20 répétitions indépendantes

Aiguille de Buffon - Distribution de l'estimateur




- Rapport $\frac{L}{D} = 0.3$
- Nombre de lancers :
 $n = 100$
- 1 000 000 répétitions indépendantes
- Moyenne :

$$m = 3.289791$$

- Variance :

$$s^2 = 0.5749353$$

Aiguille de Buffon - Distribution de l'estimateur




- Rapport $\frac{L}{D} = 0.3$
- Nombre de lancers :
 $n = 1000$
- 1 000 000 répétitions indépendantes
- Moyenne :

$$m = 3.154735$$

- Variance :

$$s^2 = 0.04304659$$

Aiguille de Buffon - Distribution de l'estimateur



- Rapport $\frac{L}{D} = 0.8$
- Nombre de lancers :
 $n = 100$
- 1 000 000 répétitions indépendantes
- Moyenne :

$$m = 3.172636$$

- Variance :

$$s^2 = 0.1033642$$

Soit une épreuve aléatoire définie par l'ensemble Ω des événements élémentaires (c'est-à-dire des résultats possibles). Soit \mathcal{A} l'ensemble des événements. Une **probabilité** \mathbb{P} est une application de l'ensemble des événements \mathcal{A} dans l'ensemble des réels \mathbb{R} :

$$\begin{aligned}\mathbb{P} : \mathcal{A} &\rightarrow \mathbb{R} \\ A &\mapsto \mathbb{P}[A]\end{aligned}$$

vérifiant :

- 1 $0 \leq \mathbb{P}[A] \leq 1$
- 2 $\mathbb{P}[\Omega] = 1$
- 3 Si (A_1, A_2, \dots, A_n) sont incompatibles deux à deux, alors :

$$\mathbb{P}[A_1 \cup A_2 \cup \dots \cup A_n] = \mathbb{P}[A_1] + \mathbb{P}[A_2] + \dots + \mathbb{P}[A_n]$$

- Événement impossible :

$$\mathbb{P}[\emptyset] = 0$$

- Complémentaire :

$$\mathbb{P}[\bar{A}] = 1 - \mathbb{P}[A] \quad \text{et} \quad \mathbb{P}[A] = 1 - \mathbb{P}[\bar{A}]$$

- Si (B_1, B_2, \dots, B_n) forment une partition de Ω , alors :

$$\mathbb{P}[A] = \mathbb{P}[A \cap B_1] + \mathbb{P}[A \cap B_2] + \dots + \mathbb{P}[A \cap B_n]$$

- Si A et B sont deux événements quelconques :

$$\mathbb{P}[A \cup B] = \mathbb{P}[A] + \mathbb{P}[B] - \mathbb{P}[A \cap B]$$

Si B est un événement pour lequel $\mathbb{P}[B] \neq 0$, on peut définir une nouvelle probabilité \mathbb{P}_B , appelée "**probabilité conditionnelle sachant B** " définie par :

$$\mathbb{P}_B[A] = \frac{\mathbb{P}[A \cap B]}{\mathbb{P}[B]}$$

Cette probabilité est souvent notée $\mathbb{P}[A | B]$ bien que " $A | B$ " ne soit pas un événement.

La **probabilité conditionnelle** $\mathbb{P}[A | B]$ s'écrit en fonction de la **probabilité conjointe** $\mathbb{P}[A \cap B]$:

$$\mathbb{P}[A | B] = \frac{\mathbb{P}[A \cap B]}{\mathbb{P}[B]}$$

Inversement, une probabilité conjointe peut s'écrire en fonction d'une probabilité conditionnelle (si cette probabilité peut être définie) :

$$\begin{array}{lll} \mathbb{P}[A \cap B] & = & \mathbb{P}[B] \mathbb{P}[A | B] \quad \text{si} \quad \mathbb{P}[B] \neq 0 \\ \mathbb{P}[A \cap B] & = & \mathbb{P}[A] \mathbb{P}[B | A] \quad \text{si} \quad \mathbb{P}[A] \neq 0 \end{array}$$

Si (B_1, B_2, \dots, B_n) forment une partition de Ω , alors :

$$\mathbb{P}[A] = \mathbb{P}[B_1] \mathbb{P}[A | B_1] + \mathbb{P}[B_2] \mathbb{P}[A | B_2] + \dots + \mathbb{P}[B_n] \mathbb{P}[A | B_n]$$

En particulier, si B est un événement tel que $0 < \mathbb{P}[B] < 1$, alors :

$$\mathbb{P}[A] = \mathbb{P}[B] \mathbb{P}[A | B] + \mathbb{P}[\overline{B}] \mathbb{P}[A | \overline{B}]$$

Deux événements A et B sont **indépendants** en probabilité si et seulement si :

$$\mathbb{P}[A \cap B] = \mathbb{P}[A] \times \mathbb{P}[B]$$

L'indépendance signifie que la réalisation d'un des événements ne modifie pas la probabilité de réalisation de l'autre événement :

$$\mathbb{P}[A | B] = \mathbb{P}[A] \quad \text{ou} \quad \mathbb{P}[B | A] = \mathbb{P}[B]$$

Rappels de Probabilité - Événements mutuellement indépendants

On dira que n événements (A_1, A_2, \dots, A_n) sont **mutuellement indépendants** si la probabilité conjointe de réalisation simultanée d'un nombre quelconque k de ces n événements est égale au produit des k probabilités :

Quel que soit k tel que $2 \leq k \leq n$,

$$\mathbb{P}[A_1 \cap A_2 \cap \dots \cap A_k] = \mathbb{P}[A_1] \times \mathbb{P}[A_2] \times \dots \times \mathbb{P}[A_k]$$

Dans le cas où les événements (A_1, A_2, \dots, A_n) ne sont pas mutuellement indépendants, la probabilité conjointe s'écrit :

$$\mathbb{P}[A_1 \cap A_2 \cap \dots \cap A_n] = \\ \mathbb{P}[A_1] \times \mathbb{P}[A_2 | A_1] \times \mathbb{P}[A_3 | A_1 \cap A_2] \times \dots \times \mathbb{P}[A_n | A_1 \cap A_2 \cap \dots \cap A_{n-1}]$$

Cette formule n'est qu'une généralisation de :

$$\mathbb{P}[A \cap B] = \mathbb{P}[A] \times \mathbb{P}[B | A]$$

Succession d'événements/états $(A_1, A_2, \dots, A_i, \dots)$:

La loi conditionnelle de X_{n+1} sachant les états passés ne dépend que de X_n

$$\begin{aligned}\mathbb{P}[X_{n+1} = x \mid X_1 = x_1 \cap X_2 = x_2 \cap \dots \cap X_n = x_n] \\ = \mathbb{P}[X_{n+1} = x \mid X_n = x_n]\end{aligned}$$

Donc :

$$\begin{aligned}\mathbb{P}[A_1 \cap A_2 \cap \dots \cap A_i \cap \dots] = \\ \mathbb{P}[A_1] \times \mathbb{P}[A_2 \mid A_1] \times \mathbb{P}[A_3 \mid A_2] \times \dots \times \mathbb{P}[A_i \mid A_{i-1}] \times \dots\end{aligned}$$

Le théorème de Bayes permet de calculer une probabilité *a posteriori* $\mathbb{P}[A | B]$ en fonction d'une probabilité *a priori* $\mathbb{P}[A]$:

$$\mathbb{P}[A | B] = \mathbb{P}[A] \times \frac{\mathbb{P}[B | A]}{\mathbb{P}[B]}$$

$$\mathbb{P}[A | B] = \mathbb{P}[A] \times \frac{\mathbb{P}[B | A]}{\mathbb{P}[A] \times \mathbb{P}[B | A] + \mathbb{P}[\bar{A}] \times \mathbb{P}[B | \bar{A}]}$$

Soit une épreuve aléatoire définie par l'ensemble Ω des événements élémentaires (c'est-à-dire des résultats possibles) et par une probabilité \mathbb{P} . Soit une application X qui associe à chaque événement élémentaire ω , une valeur réelle x :

$$\begin{aligned} X : \Omega &\rightarrow \mathbb{R} \\ \omega &\mapsto x = X(\omega) \end{aligned}$$

On appellera X **variable aléatoire réelle**.

L'ensemble des valeurs que peut prendre la variable aléatoire X , c'est-à-dire $X(\Omega)$, est appelé **support**.

Une variable aléatoire réelle X est complètement définie par sa **fonction de répartition** F :

$$F(x) = \mathbb{P}[X \leq x] \quad \text{pour} \quad x \in \mathbb{R}$$

Toute fonction de répartition vérifie :

- $0 \leq F(x) \leq 1$ pour tout $x \in \mathbb{R}$
- F est une fonction croissante
- $\lim_{x \rightarrow -\infty} F(x) = 0$
- $\lim_{x \rightarrow +\infty} F(x) = 1$
- F est continue à droite

Une variable aléatoire réelle est **discrète** si son support $X(\Omega)$ est **fini** ou **dénombrable**.

Une variable aléatoire réelle est (absolument) **continue** si sa fonction de répartition F est **continue et dérivable** sur \mathbb{R} .

La **loi de probabilité** d'une variable aléatoire réelle discrète X est définie par l'ensemble des doublets (x_i, p_i) (pour $i = 1, 2, \dots, n$ ou ∞) tel que :

- x_i est l'une des valeurs possibles de X et
- p_i est la probabilité que X soit égale à x_i , $\mathbb{P}[X = x_i] = p_i$, c'est-à-dire la probabilité d'observer les événements élémentaires ω associés à la valeur x_i .


L'ensemble des probabilités p_i doit vérifier les conditions suivantes :

$$0 \leq p_i \leq 1 \quad \text{et} \quad \sum_{i=1}^{n \text{ ou } \infty} p_i = 1$$

Variable aléatoire discrète - Loi de probabilité

x_i	x_1	x_2	\dots	x_{i-1}	x_i	x_{i+1}	\dots	x_n
$\mathbb{P}[X = x_i]$	p_1	p_2	\dots	p_{i-1}	p_i	p_{i+1}	\dots	p_n

Diagramme en bâtons :



Variable aléatoire discrète - Fonction de répartition

Soit X une variable aléatoire réelle discrète de support $X(\Omega) = \{x_1, x_2, x_3, \dots, x_i, \dots\}$ (éventuellement fini) où les valeurs x_i sont triées par ordre croissant. La **fonction de répartition** F de X pour une valeur x_i du support est :


$$F(x_i) = \mathbb{P}[X = x_1] + \mathbb{P}[X = x_2] + \dots + \mathbb{P}[X = x_i]$$

Pour toute valeur réelle x comprise entre deux valeurs successives x_i et x_{i+1} du support $X(\Omega)$, la fonction de répartition est constante :

$$F(x) = F(x_i) \quad \text{pour} \quad x_i < x < x_{i+1}$$

Variable aléatoire discrète - Fonction de répartition

La représentation graphique de la fonction de répartition $F(x)$ d'une variable aléatoire discrète X est en **forme d'escalier** :



Discontinuité :


$$\mathbb{P}[X = x_i] = F(x_i) - F_g(x_i)$$

où $F_g(x_i)$ est la limite à gauche de F en x_i

Variable aléatoire continue - Fonction de densité

La **densité de probabilité** (d.d.p.) d'une variable aléatoire réelle continue X est la fonction f définie par :

$$\mathbb{P}[x < X \leq x + dx] = f(x) dx \quad \text{pour} \quad x \in \mathbb{R}$$





Toute fonction de densité de probabilité doit vérifier :

$$f(x) \geq 0 \text{ pour tout } x \in \mathbb{R} \quad \text{et} \quad \int_{-\infty}^{+\infty} f(u) du = 1$$

Variable aléatoire continue - Fonction de répartition

Fonction de répartition F de X :



$$F(x) = \mathbb{P}[X \leq x] = \int_{-\infty}^x f(u) du \quad \text{pour} \quad x \in \mathbb{R}$$



Probabilité pour une valeur x :

$$\mathbb{P}[X = x] = F(x) - F_g(x) = 0$$

Variable aléatoire continue - Graphes




Calcul de probabilité :

$$\mathbb{P}[a \leq X \leq b] = \int_a^b f(u) du = \int_{-\infty}^b f(u) du - \int_{-\infty}^a f(u) du = F(b) - F(a)$$

$$\mathbb{P}[a < X < b] = \mathbb{P}[a \leq X < b] = \mathbb{P}[a < X \leq b] = \mathbb{P}[a \leq X \leq b]$$

Fonction quantile

La fonction de quantile Q de X est la **fonction réciproque** F^{-1} de la fonction de répartition.



Pour trouver la fonction quantile, il suffit de résoudre pour $F^{-1}(x)$:

$$F(F^{-1}(x)) = x \quad \text{pour} \quad 0 < x < 1$$

L'**espérance** de X est le nombre réel noté $\mathbb{E}[X]$ et défini par :

- X discrète :

$$\mathbb{E}[X] = \sum_{i=1}^{n \text{ ou } \infty} x_i p_i$$

- X continue :

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} u f(u) du$$

La **variance** de X est le nombre réel noté $\mathbb{V}[X]$ et défini par :

- X discrète :

$$\mathbb{V}[X] = \sum_{i=1}^{n \text{ ou } \infty} (x_i - \mathbb{E}[X])^2 p_i$$

- X continue :

$$\mathbb{V}[X] = \int_{-\infty}^{+\infty} (u - \mathbb{E}[X])^2 f(u) du$$

On montre que :

$$\mathbb{V}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

avec :

- X discrète :

$$\mathbb{E}[X^2] = \sum_{i=1}^{n \text{ ou } \infty} x_i^2 p_i$$

- X continue :

$$\mathbb{E}[X^2] = \int_{-\infty}^{+\infty} u^2 f(u) du$$

Variable aléatoire X quelconque. On crée la variable Y :

$$Y = \phi(X)$$

Comment caractériser la variable Y ?

- Cas général :

Pas de résultat...

- Si X est continue et si la fonction ϕ est continue et strictement monotone, alors g , la fonction de densité de Y est définie par :

$$g(y) = \left| \frac{d\phi^{-1}}{dy}(y) \right| f(\phi^{-1}(y)) \quad \text{pour} \quad y \in \phi(X(\Omega))$$

Calculer explicitement la densité de Y nécessite donc de pouvoir exprimer la fonction réciproque ϕ^{-1} et pouvoir dériver cette dernière.

Espérance Y :

$$\mathbb{E}[\phi(X)] = \sum_{x_i} \phi(x_i) \times \mathbb{P}[X = x_i] \quad (\text{Cas discret})$$

$$\mathbb{E}[\phi(X)] = \int_{-\infty}^{+\infty} \phi(u) \times f(u) du \quad (\text{Cas continu})$$

Estimation d'une espérance (cas continu)

Espérance X :

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} u \times f(u) du$$

On tire un n -échantillon dans la loi de X :

$$\{x_1, x_2, \dots, x_n\}$$

Estimateur de $\mathbb{E}[X]$:

$$\mathbb{E}[X] \simeq \frac{1}{n} \sum_i x_i$$

Estimation d'une espérance pour une fonction de V.A.R.

Espérance $y = \phi(X)$:

$$\mathbb{E}[Y] = \int_{-\infty}^{+\infty} \phi(u) \times f(u) du$$

On tire un n -échantillon dans la loi de X :

$$\{x_1, x_2, \dots, x_n\}$$


On applique la fonction ϕ sur le n -échantillon :

$$\{\phi(x_1), \phi(x_2), \dots, \phi(x_n)\}$$

Estimateur de $\mathbb{E}[Y]$:


$$\mathbb{E}[Y] \simeq \frac{1}{n} \sum_i \phi(x_i)$$

Problème général :



$$I = \int_a^b g(x) dx$$


Méthodes classiques d'intégrations numériques :



$$I \simeq \sum_{i=1}^n \omega_i g(x_i)$$

- rectangles
- trapèzes
- Simpson

Méthodes des rectangles :




$$I \simeq I_1 = \sum_{i=1}^n \omega_i g(x_i)$$

avec

$$\omega_i = \frac{b-a}{n} \quad \text{et} \quad x_i = a + (i-1) \frac{b-a}{n}$$

Méthode de Monte-Carlo par « tirage noir ou blanc »



- m majorant de la fonction g
- U suit une loi uniforme sur $[a, b]$
- V suit une loi uniforme sur $[0, m]$

$$I \simeq m(b-a) \frac{n_S}{n}$$

avec

n_S Nombre de succès

Méthode de Monte-Carlo par « tirage noir ou blanc » - Preuve :
Rappels :

- Loi de U :

$$f_U(u) = \frac{1}{b-a} \quad \text{pour} \quad u \in [a, b]$$

$$F_U(u) = \frac{u-a}{b-a} \quad \text{pour} \quad u \in [a, b]$$

- Loi de V :

$$f_V(v) = \frac{1}{m} \quad \text{pour} \quad v \in [0, m]$$

$$F_V(v) = \frac{v}{m} \quad \text{pour} \quad v \in [0, m]$$

Méthode de Monte-Carlo par « tirage noir ou blanc » - Preuve :

$$\begin{aligned}\mathbb{P}[V \leq g(U)] &= \int_{u=a}^b \mathbb{P}[V \leq g(u) \mid U = u] f_U(u) du \\&= \int_{u=a}^b \mathbb{P}[V \leq g(u)] f_U(u) du \\&= \frac{1}{b-a} \int_{u=a}^b F_V(g(u)) du \\&= \frac{1}{m(b-a)} \int_{u=a}^b g(u) du \\&= \frac{1}{m(b-a)} I\end{aligned}$$

Méthode de Monte-Carlo par « échantillonnage »

Si la fonction g peut s'écrire :

$$g(x) = h(x) f_X(x) \quad \text{pour} \quad x \in [a, b]$$

avec f_X densité d'une variable aléatoire X de support $[a, b]$

Alors le problème d'intégration revient à un calcul d'espérance :

$$I = \int_{u=a}^b g(x) dx = \int_{u=a}^b h(x) f_X(x) dx$$

$$I = \mathbb{E}[h(X)]$$

L'intégration peut donc se généraliser à \mathbb{R}

$$I = \mathbb{E}[h(X)]$$

Donc : si $(x_1, x_2, \dots, x_i, \dots, x_n)$ est un n -échantillon de la loi de X

$$I \simeq \frac{1}{n} \sum_{i=1}^n h(x_i)$$

Le problème d'intégration revient donc à trouver une variable X adéquate et à savoir échantillonner dans sa loi.

Méthode de Monte-Carlo par « échantillonnage »

$$g(x) = h(x) f_X(x) \quad \text{pour} \quad x \in [a, b]$$

A priori, n'importe quelle variable X de support $[a, b]$ convient.
Pourvu qu'on sache générer un n -échantillon dans sa loi.

Il suffit de prendre :

$$h(x) = \frac{g(x)}{f_X(x)}$$

Méthode de Monte-Carlo par « échantillonnage simple »

Dans ce cas, la variable X est la loi uniforme sur $[a, b]$:

$$f_X(x) = \frac{1}{b-a} \quad \text{pour} \quad x \in [a, b]$$


Alors :

$$h(x) = (b-a) g(x) \quad \text{pour} \quad x \in [a, b]$$

et :

$$I = (b-a) \mathbb{E}[g(X)]$$

Méthode de Monte-Carlo par « échantillonnage simple »





$$I \simeq \frac{b-a}{n} \sum_{i=1}^n g(x_i)$$

avec $(x_1, x_2, \dots, x_i, \dots, x_n)$ un échantillon de n valeurs tirées dans la loi uniforme sur $[a, b]$.

Ressemble à la méthode des rectangles.


Méthode de Monte-Carlo par « échantillonnage suivant l'importance »

Idée : Certaines régions ont plus d'importance que d'autres sur la quantité I à estimer. Mieux vaut concentrer l'échantillonnage sur ces régions (être précis).



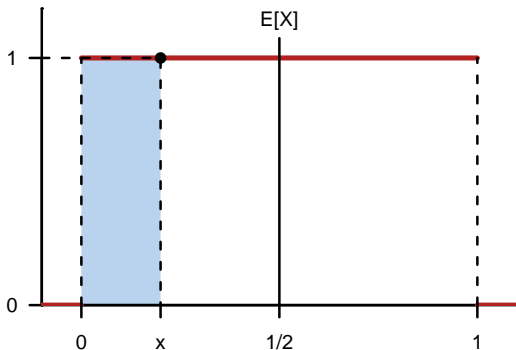
Méthode de Monte-Carlo par « échantillonnage suivant l'importance »

Il « suffit » d'échantillonner en mimant la forme de la fonction g



Simulations de variables aléatoires

La base de tout : générateur uniforme sur $[0, 1]$



Génération d'une suite de nombres par une formule tout à fait déterministe de manière à obtenir une suite qui semble aléatoire (indépendance et distribution uniforme dans l'intervalle de variation).

$$X_i = (aX_{i-1} + b) \text{ modulo } (m + 1)$$


avec a , b , m des entiers positifs.

La suite (X_i) est de période m pour des valeurs de (a, b) correctement choisies

Se transforme en générateur sur $]0, 1[$ par division par $(m + 2)$

Méthode de transformation

X : variable aléatoire continue de loi définie par sa fonction de répartition F_X



Si F_X est strictement croissante, la fonction réciproque de F_X existe, est **continue** et **croissante** : F_X^{-1}

C'est la fonction quantile $Q_X(p)$

U : variable aléatoire uniforme sur $[0, 1]$

alors :

$$Y = F_X^{-1}(U) = Q_X(U)$$

suit la loi de X

Démonstration :

$$F_Y(y) = \mathbb{P}[Y < y] = \mathbb{P}[F_X^{-1}(U) < y] = \mathbb{P}[U < F_X(y)]$$


$$F_Y(y) = F_X(y)$$

Difficulté : connaître la fonction réciproque

Méthode de transformation : Cas des lois continues


- Simuler U selon une loi uniforme $\mathcal{U}([0, 1])$
- Valeur simulée : u
- Prendre :

$$x = F_X^{-1}(u)$$



Méthode de transformation : Cas des lois discrètes

Par définition la fonction de répartition F_X n'est pas continue...



Dans la plupart des cas, il suffit de procéder par itération :

- Simuler U selon une loi uniforme $\mathcal{U}([0, 1])$
- Valeur simulée : u
- Construire $F(x)$ pas-à-pas :

$$F(x_i) = F(x_{i-1}) + \mathbb{P}[X = x_i]$$

avec :


$$F(x_0) = 0$$

- Prendre x_i si :

$$F(x_{i-1}) \leq u \leq F(x_i)$$


Méthode de transformation : Cas des lois discrètes

$$\mathbb{P}[F(x_{i-1}) \leq U \leq F(x_i)] = F(x_i) - F(x_{i-1}) = \mathbb{P}[X = x_i]$$



On définit : $F(x_0) = 0$

Loi de Bernoulli de paramètre p :



- Simuler U selon une loi uniforme $\mathcal{U}([0, 1])$
- Valeur simulée : u
- Prendre :

$$0 \text{ si } u < 1 - p \quad \text{et} \quad 1 \text{ si } u \geq 1 - p$$

ou


$$1 \text{ si } u < p \quad \text{et} \quad 0 \text{ si } u \geq p$$

Loi de Bernoulli - Implémentation R

- Simulation d'un n -échantillon uniforme sur $[0, 1]$

```
n <- 10000  
u <- runif(n)  
truehist(u)  
head(u)
```


```
[1] 0.98696722 0.05314978 0.49168854 0.64380867  
0.01060348 0.50767618
```



Loi de Bernoulli - Implémentation R


- Transformation : Bernoulli de paramètre ($p = 0.23$)

```
p <- 0.23  
x <- rep(0, n)  
x[u < p] <- 1  
plot(table(x)/n, type="h")  
head(x)  
[1] 0 1 0 0 1 0
```



Loi géométrique


Loi géométrique de paramètre p :



$$F(x) = 1 - (1 - p)^{[x]}$$

En continu :

$$F(x) = 1 - (1 - p)^x \quad \text{et} \quad F^{-1}(y) = \frac{\ln(1 - y)}{\ln(1 - p)}$$




- Simuler U selon une loi uniforme $\mathcal{U}([0, 1])$
- Valeur simulée : u
- Prendre :

$$\left\lfloor \frac{\ln(1-u)}{\ln(1-p)} \right\rfloor + 1$$

- Simulation d'un n -échantillon uniforme sur $[0, 1]$

```
n <- 10000  
u <- runif(n)  
truehist(u)  
head(u)
```


```
[1] 0.5462990 0.7740723 0.9836019 0.7098483 0.9345680  
0.2424564
```




- Transformation : Géométrie de paramètre ($p = 0.23$)

```
p <- 0.23  
x <- floor(log(1-u)/log(1-p))+1  
plot(table(x)/n, type="h")  
head(x)
```

```
[1] 4 6 16 5 11 2
```



X variable aléatoire suivant une loi exponentielle $\mathcal{E}(a)$:



$$F(x) = 1 - \exp(-ax)$$

Fonction réciproque (quantile) :

$$F^{-1}(y) = -\frac{1}{a} \ln(1 - y)$$

Loi exponentielle - Implémentation R

- Simulation d'un n -échantillon uniforme sur $[0, 1]$

```
n <- 100000
```


```
u <- runif(n)
```

```
truehist(u)
```

```
head(u)
```

```
[1] 0.56790351 0.05098637 0.47663190 0.39775107
```

```
0.89804282 0.82005418
```



Loi exponentielle - Implémentation R

- Transformation : $X = F^{-1}(U)$


```
a <- 3.4
```

```
x <- -log(1-u)/a
```

```
truehist(x)
```


```
head(x)
```

```
[1] 0.2467960 0.0153918 0.1904324 0.1491425 0.6715301  
0.5044410
```



Loi de Cauchy

X variable aléatoire suivant une loi de Cauchy de paramètres :



$$F(x) = \frac{1}{\pi} \arctan(x) + \frac{1}{2}$$

Fonction réciproque (quantile) :

$$F^{-1}(y) = \tan\left(\pi\left(y - \frac{1}{2}\right)\right)$$

Loi de Cauchy - Implémentation R

- Simulation d'un n -échantillon uniforme sur $[0, 1]$


```
n <- 100000
```

```
u <- runif(n)
```

```
truehist(u)
```

```
head(u)
```

```
[1] 0.3677855 0.8883514 0.1003319 0.8282950 0.3155977  
0.0346401
```



Loi de Cauchy - Implémentation R

- Transformation : $X = F^{-1}(U)$

```
x <- tan(pi*(u-1/2))  
truehist(x)  
head(x)
```

```
[1] -0.4410235 2.7331097 -3.0668002 1.6704213 -0.6541927  
-9.1527537
```

